

Tarea 2

Análisis de Fourier y marcas de agua en el dominio de la frecuencia

Profesor: Claudio Pérez F.

Auxiliar: Christian Díaz Guerra

Ayudante: Renato Cariaga Cárcamo

Ayudante de Laboratorio: Juan Pablo Pérez Caballero

1. Objetivo

El objetivo de esta tarea es implementar un sistema de marcas de agua digital utilizando técnicas de Spread-Spectrum y procesamiento en el dominio de la frecuencia mediante la Transformada de Fourier. Se busca que el estudiante aprenda a inyectar señales pseudoaleatorias de forma invisible, utilizando la simetría conjugada y filtros de anillo para manipular el espectro de luminancia. Además, se pretende evaluar la capacidad de detección ciega mediante correlación estadística y analizar la robustez de la información oculta frente a distorsiones y ataques comunes en imágenes digitales.

2. Descripción

Distinguir una fotografía real de una imagen generada por Inteligencia Artificial es un desafío crítico. En los primeros años, cuando las imágenes se generaban con arquitecturas como GAN, buscar huellas accidentales de la IA, como patrones de tablero de ajedrez en las altas frecuencias, era suficiente¹². Hoy, los modelos modernos evaden estas detecciones pasivas.

Para combatir esto, la industria (como [SynthID](#) de Google) inyecta firmas activas e invisibles, muchas de las cuales son secretos industriales, para evitar posibles ataques y borrados de estas marcas.

Una de las soluciones viene de la inyección de marcas de agua en el espectro de la frecuencia, las cuales ya se utilizan desde hace bastante tiempo, como lo es el **Espectro Ensanchado (Spread-Spectrum)** en donde se inyecta ruido Gaussiano tenue distribuido en miles de frecuencias.

En esta tarea, implementará un sistema simple de marca de agua utilizando esta idea.

En todas las secciones, **el análisis de los resultados es tan importante como la implementación misma.**

2.1. Spread-Spectrum puro

Para implementar el marcado de imágenes utilizando Spread-Spectrum, debe trabajar en el espacio de frecuencias por medio de la transformada de Fourier. Además, en fotografías a color, nunca marcamos los canales RGB directamente, sino que utilizamos el espacio **YCbCr** para esconder la señal en el canal de luminancia o brillo, evitando distorsiones de tono.

Realice lo siguiente:

¹ Wang, S., et al, “CNN-generated images are surprisingly easy to spot...for now,” in CVPR, 2020.

² A. Odena, V. Dumoulin, C. Olah. “Deconvolution and Checkerboard Artifacts,” in Distill, 2016.

1. Cargue la fotografía **perro.jpg** a color. Conviértala del espacio BGR/RGB al espacio YCrCb (en OpenCV: `cv2.cvtColor(img, cv2.COLOR_BGR2YCrCb)`). Separe los tres canales y guarde el **canal Y (Luminancia)** como una matriz **float32**. Los canales Cr y Cb no se tocarán por ahora.
2. Calcule el espectro 2D **centrado** (`fftshift(fft2)`) **solo del canal Y**. Separe la Magnitud ($Mag=|F|$) y la Fase (ángulo).
3. Genere una matriz X del mismo tamaño que la imagen, con valores aleatorios de una distribución Normal estándar $\mathcal{N}(0,1)$. Para que la imagen resultante sea real, el ruido en Fourier debe tener simetría conjugada. Cree:

$$X_{sym} = \frac{X + \text{rot90}(X, 2)}{2}$$

4. Cree una máscara binaria M en forma de anillo que valga 1 solo en las frecuencias medias (ej. radios entre 40 y 100 píxeles desde el centro) y 0 en el resto.
5. Modifique la magnitud original del canal Y sumando el ruido escalado proporcionalmente a la propia magnitud del coeficiente:

$$Mag' = \max(0, Mag \cdot (1 + \alpha \cdot X_{sym} \cdot M))$$

6. Recombine la nueva magnitud con la fase original ($F' = Mag' \cdot e^{j \cdot Fase}$) y aplique la transformada inversa para obtener el nuevo canal de luminancia marcado, Y_{marca} .
7. Una su nuevo Y_{marca} con los canales Cr y Cb originales. Convierta la imagen de vuelta a BGR/RGB (recuerde clipear los valores). Calcule el **PSNR** entre la imagen a color original y la marcada.

HINT: Convierta las imágenes a punto flotante. Calcule el Error Cuadrático Medio (MSE) promediando el error sobre los tres canales a la vez: $MSE = \text{media}((I - I_{marca})^2)$. Luego aplique $PSNR = 10 \cdot \log_{10} \left(\frac{255^2}{MSE} \right)$.

8. **Detección de la marca:** En un escenario real, el receptor no posee la imagen original. Para detectar la marca de forma ciega, cargue la imagen marcada, conviértala a YCrCb, extraiga el canal Y y calcule su Magnitud de Fourier (Mag^*). Multiplique esta magnitud por la máscara de anillo M para anular las frecuencias donde sabemos que no hay información. Luego, calcule el **Coefficiente de Correlación de Pearson** directamente entre esta magnitud enmascarada ($Mag^* \cdot M$) y su clave original X_{sym} .
9. Aunque los coeficientes de la imagen actúan como una fuerte interferencia, debido a la ortogonalidad del ruido pseudoaleatorio, el valor de correlación debería resaltar. Compárelo contra 3 claves aleatorias falsas y muestre los resultados en un gráfico de barras. Debería notar que solo la clave original produce una alta correlación. Repita el proceso desde el paso 5 al 8 con valores de $\alpha \in \{0.5, 2.0, 5.0\}$ (recuerde mostrar los valores de PSNR para cada caso).

Análisis: ¿Qué sucede con valores muy altos de α en la imagen y en la correlación obtenida? ¿Se puede notar la marca a simple vista en la imagen? ¿Qué sucede con el fondo que tiene un color más plano? ¿Qué valor de α le resultó mejor, considerando la correlación y la visibilidad de la marca?

2.2. Adaptación espacial utilizando la textura

Es probable que haya notado que el ojo humano nota el ruido inmediatamente en zonas lisas (el fondo), pero es ciego al ruido en zonas con mayor textura (el pelaje del perro). En lugar de adaptar el ruido a la energía de la frecuencia, lo adaptaremos a la textura del espacio de la imagen utilizando la **Entropía Local**, haciendo un puente entre el dominio de la frecuencia y el dominio espacial.

Realice lo siguiente:

1. Genere su matriz de ruido Gaussiano $\mathcal{N}(0,1)$ en el dominio espacial. Pásela a Fourier, multiplíquela por el Anillo M de frecuencias medias, y devuélvala al espacio (IFFT) tomando la parte real. Ahora tiene un ruido de frecuencias medias, K_{band} .
2. Usando el **canal Y (Luminancia) original**, calcule la entropía local (puede usar `skimage.filters.rank.entropy` con un disco de radio 3 o 4). Normalice este mapa E para que sus valores estén entre 0 y 1. Zonas de alta textura tendrán valores cercanos a 1.
3. Sume el ruido directamente al canal Y original en el dominio espacial, forzando a que la amplitud (α) sea modulada (suprimida) en las zonas lisas por el mapa de entropía:
$$Y_{marca} = Y + \alpha \cdot E \cdot K_{band}$$
4. Una este nuevo canal Y_{marca} con los canales Cr y Cb originales, convierta a RGB y visualice.
5. Utilizando el α óptimo que encontró en la Parte 1, compare visualmente el grano de la imagen. Luego, intente subir el α en esta técnica hasta que el PSNR sea similar al de la parte anterior.
6. A diferencia de la sección anterior, dado que inyectamos la marca en el dominio espacial, **la detección debe realizarse calculando la correlación en el dominio espacial** (directamente sobre los píxeles). Note que en este caso la clave espacial debería ser $E \cdot K_{band}$. Sin embargo, en un sistema real, la idea sería solo guardar la semilla del ruido K_{band} y no la entropía de cada imagen (lo que dejaría de ser una marca universal). Realice la detección en dos escenarios (nuevamente usando 3 claves falsas), utilizando ambos valores de α del paso 5:
 - a. Detección Informada: Utilice el mapa de entropía original E (calculado en el paso 2 sobre la imagen limpia) para formar la clave espacial ($E \cdot K_{band}$). Aplane las matrices (flatten) y calcule el Coeficiente de Correlación de Pearson **directamente entre el canal Y_{marca} y esta clave espacial**.
 - b. Detección Ciega: Simule el escenario real: recalcule el mapa de entropía local (llamémoslo $E_{marcado}$) utilizando únicamente la imagen que ya contiene la marca. Forme su clave espacial aproximada ($E_{marcado} \cdot K_{band}$). Aplane las matrices y calcule el Coeficiente de Correlación de Pearson **entre el canal Y_{marca} y esta nueva clave**.

Análisis: ¿Qué cambios observa en el fondo con respecto al método de la sección 2.1? ¿El valor de α con respecto al PSNR es más alto o bajo que el método anterior? ¿Por qué? Finalmente, compare los dos escenarios de detección del paso 6: ¿Logra la Detección Ciega encontrar la firma usando el $E_{marcado}$? ¿Qué tanto disminuye el valor de correlación en comparación con usar el E original y por qué ocurre este fenómeno?

2.3. Marcado en el dominio Wavelet (DWT)

Aunque en la sección anterior es probable que haya logrado esconder la marca, al realizarse en el dominio espacial, resulta más frágil a ataques. Otra solución es utilizar la **Transformada Wavelet Discreta (DWT)**, la cual ofrece una representación conjunta en el dominio espacio-frecuencia. Al aplicar la DWT en 2D, la imagen se descompone en cuatro sub-bandas: LL (aproximación de bajas frecuencias), HL (detalles horizontales), LH (detalles verticales) y HH (detalles diagonales de alta frecuencia). Para equilibrar invisibilidad y robustez, inyectaremos nuestra firma de ruido pseudoaleatorio en las sub-bandas de frecuencias medias (HL y LH), evitando la banda LL (para no alterar la luminosidad general) y la banda HH (ya que la compresión JPEG la destruye fácilmente). Para este método se recomienda instalar y usar la librería **PyWavelets** (`pip install PyWavelets`). Realice lo siguiente:

1. Cargue la imagen original, conviértala a YCrCb y extraiga el canal Y en punto flotante, tal como en las secciones anteriores.
2. Aplique la transformada DWT 2D sobre el canal Y utilizando la familia wavelet de Haar:
`coeffs = pywt.dwt2(Y, 'haar')`. Esto le retornará una tupla con la estructura (LL, (LH,

HL, HH). Notará que estas matrices tienen la mitad de la resolución espacial que la imagen original.

3. Genere una matriz de ruido pseudoaleatorio Gaussiano $\mathcal{N}(0,1)$ con una semilla fija. Esta matriz X_{key} debe tener exactamente el mismo tamaño que las sub-bandas (es decir, la mitad del tamaño de la imagen Y).
4. Modifique las sub-bandas de frecuencias medias sumando el ruido escalado por un factor α . A diferencia de la transformada de Fourier, aquí la modificación es aditiva directa sobre los coeficientes reales de la transformada:

$$HL_{marca} = HL + \alpha \cdot X_{key}$$

$$LH_{marca} = LH + \alpha \cdot X_{key}$$

5. Reemplace las sub-bandas originales por las marcadas creando una nueva tupla `coeffs_marca = (LL, (LH_marca, HL_marca, HH))`. Aplique la transformada inversa (`pywt.idwt2`) para obtener su nuevo canal de luminancia espacial marcado, Y_{marca} .
6. Una el nuevo Y_{marca} con los canales Cr y Cb originales, clipee los valores y convierta a RGB. Encuentre empíricamente el valor de α que iguale el PSNR obtenido en la Parte 1.
7. Para simular un escenario real, asuma que solo tiene la imagen marcada:
 - a. Conviértala a YCrCb y extraiga el canal Y.
 - b. Aplique la transformada DWT 2D sobre este canal para obtener los coeficientes en evaluación, particularmente HL^* y LH^* .
 - c. Aplane las matrices (flatten) y calcule la Correlación de Pearson entre la sub-banda extraída HL^* y la clave original X_{key} . Puede promediar las correlaciones obtenidas en HL y LH para mayor robustez.
 - d. Compare contra 3 claves falsas (matrices de ruido con semillas distintas del mismo tamaño).

2.4. Resiliencia a ataques

Las marcas de agua desarrolladas anteriormente podrían ser muy frágiles a ataques que intenten suprimirla, lo que haría inútil nuestro método desarrollado. En esta sección se pondrán a prueba con cuatro ataques clásicos. Para ello, utilice los tres métodos desarrollados anteriormente y compárelos (ocupe el mejor α en cada caso).

En primer lugar, se debe seleccionar un umbral sobre el cual se pueda argumentar que la imagen está marcada. Para ello, realice lo siguiente:

1. Genere **100 claves falsas** (matrices de ruido con semillas aleatorias distintas, pasadas por el mismo proceso de filtrado/enmascaramiento).
2. Calcule la Correlación de Pearson de su imagen marcada contra estas 100 claves falsas.
3. Calcule la media (μ) y la desviación estándar (σ) de estas 100 correlaciones (deberían ser valores muy cercanos a cero).
4. Defina su Umbral de Detección (T) usando la regla empírica de la estadística para descartar valores atípicos: $T = \mu + 3\sigma$.
5. Calcule la correlación de la imagen marcada contra la clave correcta. Verifique que este valor sea abismalmente superior a su umbral T. Grafique los 101 valores (100 falsas + 1 correcta) para visualizar el pico de detección.

Ahora pruebe los siguientes ataques y aplique la detección de la marca de agua. En cada caso muestre la imagen original marcada, la imagen filtrada y su valor de correlación original y de la nueva imagen, junto con el umbral impuesto:

1. Gaussian Blur: Aplique un filtro gaussiano con $\sigma = 5$ y tamaño 15.

Análisis: Al aplicar un filtro Gaussiano agresivo, la imagen pierde nitidez y detalles finos. ¿Se sigue encontrando la marca para cada caso? Relacione su respuesta con la magnitud de los coeficientes de Fourier donde elegimos inyectar la marca y cómo se manejan las texturas en los métodos 2 y 3.

2. Ruido aleatorio (interferencia): Sume ruido aleatorio con media 0 y desviación estándar 20.

Análisis: Si la marca de agua es ruido Gaussiano, y el ataque consiste en sumarle más ruido Gaussiano encima, la imagen espacialmente se vuelve un desastre. ¿Por qué la similitud (correlación) de nuestra clave correcta casi no se ve afectada por este nuevo ruido?

3. Cropping: Recorte la mitad inferior de la imagen. Debido a que debe mantener el tamaño de la imagen, impleméntelo haciendo cero esa zona.

Análisis: Hemos destruido espacialmente la mitad exacta de los píxeles de la imagen. ¿En qué casos la marca sobrevive? Explique por qué un recorte espacial no equivale a borrar un trozo del espectro de frecuencias.

4. Compresión JPEG: Comprima su imagen en JPEG en calidad 15 (puede utilizar `cv2.imencode`).

Análisis: Dado que el algoritmo JPEG suprime fuertemente las altas frecuencias para ahorrar espacio, ¿cómo justifica que nuestra marca de agua, ubicada en el anillo de frecuencias medias, logre o no sobrevivir a esta compresión agresiva?

3. Entregables

1. Reporte (PDF): Un documento con sus explicaciones y análisis de cada sección. Este reporte debe incluir las imágenes solicitadas.

2. Código Fuente: Scripts o Jupyter Notebooks documentados. Asegúrese de que las rutas a las imágenes sean relativas para que el equipo docente pueda ejecutar su código. El código debe poder ser ejecutado sin mayores cambios ni errores, y debe generar los resultados presentados en el reporte.

Fecha de entrega: 2 de junio a las 23:59 hrs mediante U-Cursos.