

# Tarea 3

Compensación de iluminación, normalización de color y segmentación de imágenes histológicas

**Profesor: Claudio Pérez F.**

Auxiliar: Christian Díaz G.

Ayudante: Renato Cariaga C.

Ayudante de Laboratorio: Juan Pablo Pérez C.

## 1. Objetivo

El objetivo de esta tarea es estudiar cómo distintas técnicas de preprocesamiento modifican la información contenida en imágenes histológicas teñidas con Hematoxilina y Eosina (H&E), y cómo dichos cambios afectan el desempeño de distintos algoritmos de segmentación de núcleos celulares. La tarea busca enfatizar que una transformación que a simple vista parecería mejor, no conduce necesariamente a un mejor desempeño en tareas posteriores, y que el efecto del preprocesamiento depende fuertemente de la representación utilizada por el segmentador.

## 2. Descripción

El análisis histológico de tejidos teñidos con Hematoxilina y Eosina (H&E) es fundamental en la detección de enfermedades relacionadas, como el cáncer. Sin embargo, las imágenes adquiridas generalmente presentan alta variabilidad visual, debido a diferencias en protocolos médicos, como lo son el procedimiento de tinción de muestras, el escáner utilizado y el protocolo de adquisición. Para reducir esta variabilidad, se utilizan técnicas de normalización, las que, por ejemplo, pueden actuar sobre la luminancia de la imagen o su distribución de colores.

El problema es que estas transformaciones no siempre tienen el mismo resultado: un pipeline clásico basado en separación de tinciones y un modelo de Deep Learning utilizan representaciones fundamentalmente distintas, y lo que mejora la entrada de uno puede distorsionar la del otro. En esta tarea se caracterizará el efecto de cada transformación de forma aislada y luego se medirá su impacto sobre ambos tipos de segmentador.

**Para esta tarea se recomienda el uso de Google Colab.**

**En todas las secciones, el análisis de los resultados es tan importante como la implementación misma.**

## 3. Dataset

Se utilizará un subconjunto del dataset **MoNuSeg**<sup>1</sup> compuesto por 8 imágenes histológicas H&E junto a sus máscaras de segmentación de referencia, las cuales se encuentran en la carpeta **data/**. Adicionalmente, se entregará una imagen histológica de referencia para normalización de color (**data/reference.tif**), la cual **no forma parte del conjunto de evaluación**.

---

<sup>1</sup> <https://www.kaggle.com/datasets/tuanledinh/monuseg2018>

## 4. Preprocesamiento

### 4.1. Funciones auxiliares

Implemente las siguientes funciones de apoyo que serán utilizadas a lo largo de la tarea.

- `plot_histogram_rgb(img)`: Grafica la distribución de intensidades de cada canal RGB de la imagen de entrada.
- `compute_lab_statistics(img)`: Calcula y retorna la media y desviación estándar por canal en el espacio LAB.

### 4.2. Normalización de luminancia

Implemente las siguientes funciones, las cuales operan en el espacio LAB (`cv2.COLOR_RGB2LAB`) modificando únicamente el canal L.

#### 4.2.1. Ecualización de histograma (HE)

Implemente `equal_hist_l(img)`, el cual:

1. Convierte la imagen RGB a LAB.
2. Aplica ecualización de histograma sobre el canal L. **No se permite usar implementaciones existentes.**
3. Reconstruir la imagen RGB.

La ecualización se realiza mediante una *look-up table* construida a partir del histograma acumulado normalizado:

$$O_{i,j} = \lfloor (L - 1) \times H'(I_{i,j}) \rfloor$$

donde  $H'$  es el histograma acumulado normalizado y  $L = 256$ .

#### 4.2.2. CLAHE

Implemente `clahe_l(img)` el cual debe:

1. Convertir RGB a LAB.
2. Aplicar CLAHE sobre el canal L usando `cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8,8))`
3. Reconstruir la imagen RGB.

### 4.3. Normalización de color

En histología, es común que imágenes provenientes de distintos laboratorios presenten diferencias de color importantes debido a variaciones en los protocolos de tinción, el tipo de escáner o las condiciones de adquisición. Por ello, existen técnicas de normalización de color que buscan hacer que todas las imágenes se vean como si hubieran sido adquiridas bajo las mismas condiciones. Una de las más simples es la normalización de Reinhard<sup>2</sup>, que adapta la distribución de color de una imagen hacia la de una imagen de referencia operando canal a canal en el espacio LAB. En esta sección deberá implementar

---

<sup>2</sup> E. Reinhard, M. Adhikhmin, B. Gooch, y P. Shirley, "Color transfer between images", IEEE Comput. Graph. Appl., vol. 21, núm. 4, pp. 34–41, 2001.

**reinhard\_normalization(source, target)**, donde *source* es la imagen a normalizar y *target* es la imagen de referencia entregada. Para ello:

1. Convierta ambas imágenes a LAB.
2. Calcule la media y desviación estándar por canal en ambas imágenes.
3. Para cada canal, escale la distribución de *source* hacia la distribución de *target*. La transformación de cada canal está dada por:

$$O_c = \frac{\sigma_{t,c}}{\sigma_{s,c}} \cdot (I_c - \mu_{s,c}) + \mu_{t,c}$$

Donde *t* es el target, *s* el source, *c* el canal,  $\mu, \sigma$  la media y desviación estándar e  $I_c$  el canal *c* de la imagen.

4. Reconstruya la imagen RGB.

**No se permite usar implementaciones existentes de Reinhard.**

## 4.4. Análisis del preprocesamiento

Aplique cada una de las 3 transformaciones (HE, CLAHE y Reinhard) por separado a las 8 imágenes del dataset. A partir de ello, responda las siguientes preguntas, apoyándose de histogramas RGB, estadísticas LAB, visualizaciones de imágenes y lo que usted estime conveniente.

1. ¿Qué transformaciones afectan principalmente el canal L y cuáles afectan los canales a/b? Justifique con las estadísticas LAB antes y después de cada transformación. Puede calcular las diferencias de cada canal contra la imagen original.
2. Calcule la desviación estándar de las medias LAB entre las imágenes, antes y después de cada transformación. ¿Qué transformación reduce más efectivamente la variabilidad entre muestras? ¿Tiene sentido este resultado?
3. ¿Existe alguna transformación que genere un cambio estadístico notable en LAB pero que no mejore perceptualmente la imagen, o viceversa?
4. La normalización de Reinhard depende de la imagen de referencia elegida. Analice la imagen de referencia entregada en comparación con las de las 8 imágenes del dataset. ¿En qué medida la referencia es “representativa” del dataset? ¿Qué ocurriría si se eligiera una referencia con estadísticas LAB muy distintas, por ejemplo, una imagen con dominancia de un tono diferente? Puede apoyarse en estadísticas del espacio LAB y otras que estime conveniente.

## 5. Segmentación

En esta sección tendrá que implementar dos algoritmos de segmentación, uno clásico y otro basado en Deep learning, utilizando los preprocesamientos de la sección anterior y comparando sus resultados.

### 5.1. Pipeline clásico

Aunque la tinción H&E tiende a separar visualmente los núcleos celulares del tejido circundante, haciendo que los núcleos aparezcan teñidos de azul/violeta por la Hematoxilina y el citoplasma de rosa por la Eosina, trabajar directamente sobre la imagen RGB dificulta la segmentación debido a la variabilidad de color entre imágenes. Es por ello que se utilizan técnicas de separación de tinciones, que descomponen la imagen en sus componentes de Hematoxilina y Eosina de forma independiente. Una de

las más utilizadas es el método de Macenko<sup>3</sup>, que estima la matriz de deconvolución directamente desde los datos mediante análisis de componentes principales en el espacio óptico.

Para el pipeline clásico, se utilizará el canal de Hematoxilina, junto a umbral Otsu y Watershed para encontrar los núcleos de las células. Para ello:

1. Utilice una implementación existente de la deconvolución de Macenko (e.g. **torchstain**) para separar los canales de Hematoxilina (H) y Eosina E de cada imagen. Notar que, en este caso, no hay ninguna imagen de referencia extra.
2. Usando solo el canal H en escala de grises, utilice **skimage.filters.threshold\_otsu** para imponer un umbral.
3. Utilice operaciones morfológicas para limpiar la máscara (apertura/cierre según convenga).
4. Aplique Watershed (**skimage.segmentation.watershed**) para separar núcleos solapados.

## 5.2. Pipeline Deep Learning

Para esta sección, se utilizará el modelo preentrenado Cellpose<sup>4</sup>, el cual es un modelo de segmentación de células y núcleos general, que opera directamente sobre imágenes RGB. Para ello, deberá instalar el modelo utilizando **pip install cellpose**. Con ello, podrá utilizarlo con **cellpose.models.CellposeModel(gpu=True)**, el cual la primera vez descargará el modelo.

## 5.3. Evaluación

Para ambos pipelines (clásico y Deep Learning), reporte Dice e IoU  $\text{media} \pm \text{std}$  calculado entre la máscara predicha y de ground truth. Utilice: la imagen original, preprocesamiento HE, CLAHE y Reinhard (cada uno por separado, 4 resultados para cada pipeline). Guarde además el resultado de cada imagen para su posterior análisis. Debe notar que la máscara podría no ser del mismo tamaño que la imagen, por lo que debe realizar un redimensionamiento con una interpolación adecuada.

## 5.4. Análisis de la segmentación

Responda las siguientes preguntas en base a resultados cuantitativos, visualizaciones de las segmentaciones obtenidas, estadísticas LAB, y lo que estime conveniente.

1. ¿El canal Hematoxilina obtenido tras aplicar HE o CLAHE difiere del obtenido sobre la imagen original?
2. ¿Qué pipeline resulta más sensible al preprocesamiento? ¿A qué se debe esta diferencia considerando cómo cada uno representa la imagen internamente?
3. ¿Existe algún preprocesamiento que mejore consistentemente un pipeline pero perjudique al otro? Apoya tu respuesta con las métricas y muestra un ejemplo visual representativo.
4. ¿Existe relación entre calidad visual y desempeño cuantitativo?
5. ¿Existe alguna imagen donde ambos pipelines fallen independientemente del preprocesamiento? Si es así, ¿qué característica visual de esa imagen podría explicar el bajo desempeño?
6. Considerando tanto la media como la varianza del Dice entre imágenes, ¿qué pipeline y qué preprocesamiento recomendarías para un sistema que debe procesar imágenes provenientes de múltiples hospitales?

<sup>3</sup> M. Macenko et al., “A method for normalizing histology slides for quantitative analysis”, en 2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro, 2009.

<sup>4</sup> <https://github.com/mouseland/cellpose>

## 6. Entregables

- 1. Reporte (PDF):** Un documento con sus explicaciones y análisis de cada sección. Este reporte debe incluir las imágenes solicitadas.
- 2. Código Fuente:** Scripts o Jupyter Notebooks documentados. Asegúrese de que las rutas a las imágenes sean relativas para que el equipo docente pueda ejecutar su código. El código debe poder ser ejecutado sin mayores cambios ni errores, y debe generar los resultados presentados en el reporte.

**Fecha de entrega: 24/06/2026 a las 23:59 hrs mediante U-Cursos.**