

Tarea 3

Compensación de iluminación, normalización de color y segmentación de imágenes histológicas

Integrante:	Felipe González
Profesor:	Claudio Pérez
Auxiliar:	Christian Díaz Guerra
Ayudante:	Renato Cariaga
Ayudante de laboratorio:	Juan Pérez
Fecha de entrega:	26 de junio de 2026
Santiago de Chile	

Índice de Contenidos

1. Análisis del preprocesamiento	1
2. Análisis de la segmentación	3

Índice de Figuras

1. Muestra con distintos preprocesamientos	1
--	---

Índice de Tablas

1. Desviaciones estandar de la media de cada imagen por cada tipo de preproce- samiento	1
2. Resultados del pipeline clásico	3
3. Resultados del pipeline de Deep Learning	3

1. Análisis del preprocesamiento

Pregunta 1 ¿Qué transformaciones afectan principalmente el canal L y cuáles afectan los canales a/b? Justifique con las estadísticas LAB antes y después de cada transformación. Puede calcular las diferencias de cada canal contra la imagen original.

Las transformaciones que afectan principalmente solo al canal L son la ecualización de histograma y *Contrast Limited Adaptive Histogram Equalization*. Como la implementación hace un cambio directo sobre el canal L, es natural observar un mayor cambio en el canal dicho. Al observar la figura 1, se pueden ver los distintos preprocesamientos.




Figura 1: Muestra con distintos preprocesamientos

Pregunta 2 Calcule la desviación estándar de las medias LAB entre las imágenes, antes y después de cada transformación. ¿Qué transformación reduce más efectivamente la variabilidad entre muestras? ¿Tiene sentido este resultado?

Si vemos la tabla 1, se puede notar que el método que más reduce la variabilidad es *Reinhard*. Esto ocurre principalmente porque se le está restando la media propia del canal, normalizando para que su desviación estándar sea 1 y luego finalmente se convierte artificialmente para que todas las imágenes tengan la distribución estadística de la imagen objetivo.

Tabla 1: Desviaciones estandar de la media de cada imagen por cada tipo de preprocesamiento

	Canal L	Canal a	Canal B
Original:	27.02	7.11	3.75
HE:	0.41	6.57	3.75
CLAHE:	6.70	6.84	3.72
Reinhard:	0.16	0.09	0.04

Pregunta 3 ¿Existe alguna transformación que genere un cambio estadístico notable en

LAB pero que no mejore perceptualmente la imagen, o viceversa?

Sí, se observan ambos fenómenos dependiendo del método. Por un lado, la normalización de Reinhard genera un cambio estadístico profundo en los tres canales del espacio LAB (como evidencia la caída casi nula de la desviación estándar en la Tabla 1). Sin embargo, este ajuste drástico a la distribución objetivo no necesariamente mejora la imagen perceptualmente. No aumenta la claridad de las estructuras e incluso puede generar colores poco naturales o artefactos que la empeoran visualmente.

Por el contrario, ocurre el caso inverso con técnicas como CLAHE y HE. Estas alteran estadísticamente un solo canal (la luminancia, L), dejando casi intacta la variabilidad de los canales de color (a y b). A pesar de este cambio estadístico más acotado, logran una mejora perceptual sustancial, ya que realzan el contraste y facilitan enormemente la distinción visual de los núcleos celulares frente al tejido circundante.

Pregunta 4 La normalización de Reinhard depende de la imagen de referencia elegida. Analice la imagen de referencia entregada en comparación con las de las 8 imágenes del dataset. ¿En qué medida la referencia es representativa del dataset? ¿Qué ocurriría si se eligiera una referencia con estadísticas LAB muy distintas, por ejemplo, una imagen con dominancia de un tono diferente?

La imagen de referencia entregada resulta altamente representativa porque posee un balance adecuado entre las estructuras teñidas con Hematoxilina y Eosina. Visualmente presenta núcleos claramente definidos en tonos oscuros y citoplasma en tonos rosados bien contrastados. Al poseer estadísticas LAB equilibradas, actúa como un punto medio ideal. Esto permite que al aplicar la transformación de Reinhard, la cual escala y desplaza la distribución de color de la imagen original hacia la de referencia, las muestras corrijan sus problemas de iluminación sin perder la coherencia biológica de sus colores.

Si se eligiera una referencia con estadísticas LAB atípicas, los resultados afectarían negativamente la imagen. Dado que el método ajusta la media y desviación estándar canal por canal basándose exclusivamente en el target, una imagen de referencia con dominancia de un solo tono obligaría a todas las muestras a adoptar ese mismo sesgo. Por ejemplo, una referencia excesivamente rosada teñiría los núcleos oscuros de ese mismo color, destruyendo el contraste natural del tejido. Esto afectaría gravemente el desempeño de la segmentación. El pipeline clásico fallaría al intentar separar la Hematoxilina y el modelo de Deep Learning perdería las características de contraste necesarias para detectar los núcleos celulares.

2. Análisis de la segmentación

Tabla 2: Resultados del pipeline clásico

Preprocesamiento	DICE	IoU
Original	0.6608 ± 0.0957	0.5001 ± 0.0935
HE	0.6231 ± 0.0895	0.4583 ± 0.0900
CLAHE	0.6384 ± 0.0734	0.4729 ± 0.0744
Reinhard	0.6539 ± 0.1054	0.4937 ± 0.1004

Tabla 3: Resultados del pipeline de Deep Learning

Preprocesamiento	DICE	IoU
Original	0.5553 ± 0.0895	0.3892 ± 0.0766
HE	0.5854 ± 0.0916	0.4192 ± 0.0836
CLAHE	0.5783 ± 0.0897	0.4118 ± 0.0802
Reinhard	0.5522 ± 0.0896	0.3861 ± 0.0763